CC3092 — Deep Learning y Sistemas Inteligentes

Hoja de Trabajo #2: Transformers y Mecanismos de Atención

Ernesto Ascencio
Carné 23009
git clone https://github.com/AscencioSIUU/deepLearning.git
Carpeta *labs/hdb-transformers*

1. De las RNN a la atención

En un seq2seq con RNN el codificador comprime toda la entrada en un único vector de contexto de tamaño fijo, que es un **cuello de botella**: la calidad cae con la longitud de la oración y el gradiente debe recorrer T pasos (desvanecimiento). **Bahdanau** (2014) permite que el decodificador consulte todos los estados del codificador: $e_{ij} = v^T \tanh(W_s s_{i-1} + W_h h_j)$ (atención **aditiva**, una MLP), $\alpha_{ij} = \mathrm{softmax}_j(e_{ij})$, $c_i = \Sigma_j \alpha_{ij} h_j$. **Luong** (2015) usa scores **multiplicativos** ($s^T h$ o $s^T W h$): equivalentes en calidad pero mucho más baratos, porque se reducen a un producto matricial. El Transformer generaliza esto con **Query/Key/Value**: la *query* de un token pregunta, las *keys* anuncian qué contiene cada token, y los *values* son lo que se lee; el resultado es un promedio de V ponderado por la compatibilidad $q \cdot k$. La atención deja de ser un complemento de una RNN y pasa a ser la única forma de mezclar información entre posiciones.

2. Arquitectura Transformer

Scaled dot-product: $\mathrm{Attention}(Q,K,V) = \mathrm{softmax}(QK^T/\sqrt{d_k})\,V$. Si las componentes de q y k son independientes con media 0 y varianza 1, $q \cdot k$ tiene varianza d_k; sin la división el softmax se satura y los gradientes se anulan. **Multi-head**: h cabezas con proyecciones propias de dimensión $d_k = d_{model}/h$ atienden en paralelo y se concatenan con W_O; permiten que cada cabeza se especialice en un tipo de relación con el mismo costo total.

Codificación posicional. La atención es invariante a permutaciones, por lo que hay que inyectar el orden. *Sinusoidal*: $PE(pos,2i)=\sin(pos/10000^{2i/d})$, $PE(pos,2i+1)=\cos(\cdot)$, sumada al embedding; el coseno entre posiciones decae con la distancia (fig. del notebook) y permite extrapolar de forma teórica. *RoPE*: rota cada par de dimensiones de q y k por $pos \cdot \theta_i$, de modo que $q_m \cdot k_n$ depende solo de $m-n$ (verificado numéricamente: −6.36248 para *(3,1)*, *(10,8)* y *(103,101)*). Es posicional-relativa, no añade parámetros y es el estándar en LLM modernos.

Bloque. Residual + LayerNorm alrededor de la atención y de una FFN. *Post-LN* (original): $LN(x+F(x))$; *Pre-LN*: $x+F(LN(x))$. Pre-LN conserva un camino identidad limpio, tiene gradientes bien escalados al inicio y entrena sin *warm-up* delicado; Post-LN suele rendir algo mejor si converge pero es inestable en modelos profundos.

Complejidad. Autoatención: $O(T^2 \cdot d)$ tiempo y $O(T^2)$ memoria por cabeza, pero profundidad secuencial $O(1)$ y camino máximo entre dos tokens $O(1)$; una RNN: $O(T \cdot d^2)$ con profundidad secuencial $O(T)$ y camino $O(T)$. Alternativas: **FlashAttention** (exacta; hace *tiling* en SRAM y no materializa la matriz $T \times T$ en HBM, memoria $O(T)$ y mucho más rápida por menor tráfico de memoria), atención dispersa/ventana (Longformer, BigBird), aproximaciones lineales (Performer) y modelos de estado (Mamba).

APIs usadas (§1 del notebook): *F.scaled_dot_product_attention* (kernel fusionado; admite *is_causal*), *nn.MultiheadAttention* (*need_weights=True, average_attn_weights=False* devuelve pesos por cabeza; *attn_mask* aditiva o booleana, *key_padding_mask*), *nn.Transformer.generate_square_subsequent_mask* (máscara aditiva con *-inf* sobre la diagonal), y en Hugging Face *AutoModel.from_pretrained(..., attn_implementation="eager")* con *output_attentions=True* (la implementación SDPA no devuelve pesos).

3. Procedimiento matemático manual

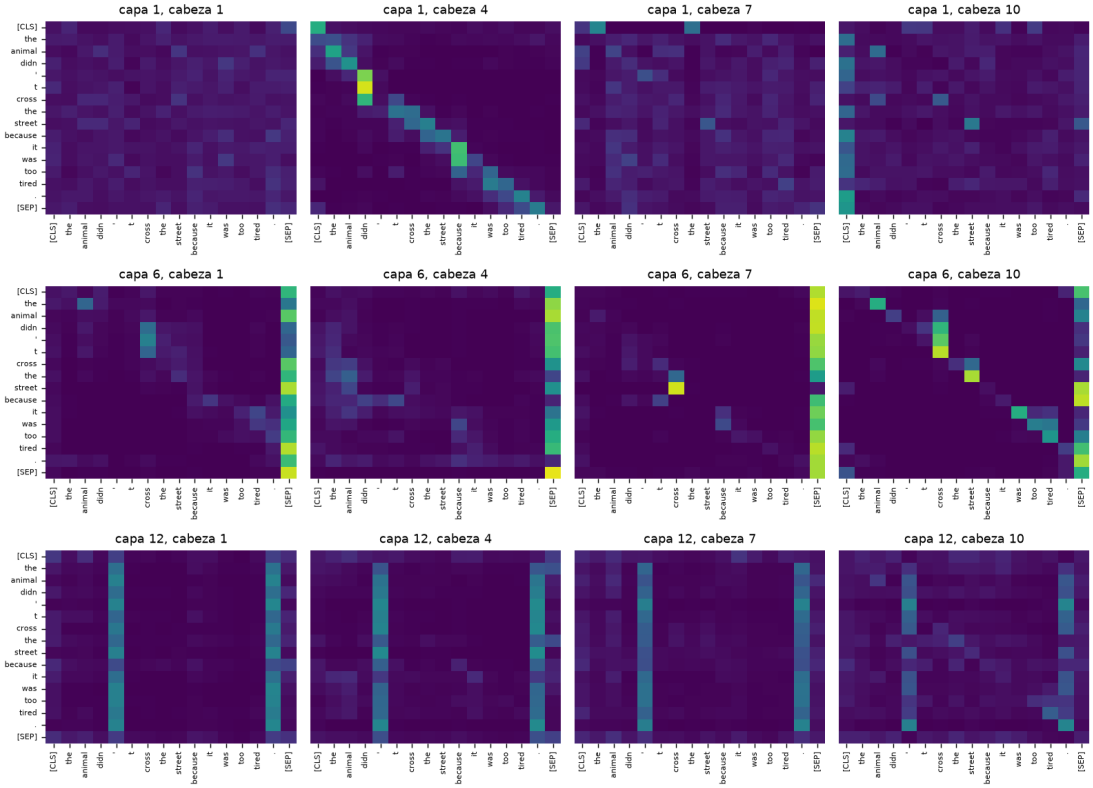
Con $d_k=4$, $Q=[[1,0,1,0],[0,2,0,2],[1,1,0,0]]$, $K=[[1,0,0,1],[0,1,1,0],[1,1,1,1]]$, $V=\mathrm{diag}(1,2,3)$:

- $QK^T = [[1,1,2],[2,2,4],[1,1,2]]$ → dividir por $\sqrt{4}=2$: $[[.5,.5,1],[1,1,2],[.5,.5,1]]$.

- Softmax por fila: fila 1 = *e^{.5},e^{.5},e^{1} / (2e^{.5}+e) = [0.2741, 0.2741, 0.4519]*; fila 2 = *[0.2119, 0.2119, 0.5761]*.
- Salida $A \cdot V$: fila 1 = *0.2741·[1,0,0]+0.2741·[0,2,0]+0.4519·[0,0,3] = [0.2741, 0.5481, 1.3556]*.
- Con máscara causal la fila 1 queda *[1,0,0]*, la fila 2 *[.5,.5,0]* y la fila 3 igual que antes.

El notebook comprueba que coincide con *F.scaled_dot_product_attention* y que *nn.MultiheadAttention* reproduce el cálculo manual por cabeza (a partir de *in_proj_weight*) con tolerancia 10^{-5}.

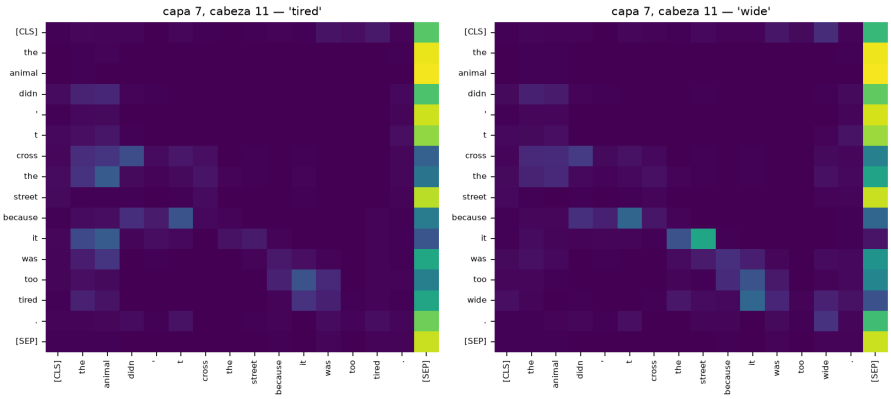
4. Experimentos en BERT y GPT-2



BERT: capas 1, 6 y 12 (filas), cabezas 1, 4, 7, 10 (columnas), sobre "The animal didn't cross the street because it was too tired."

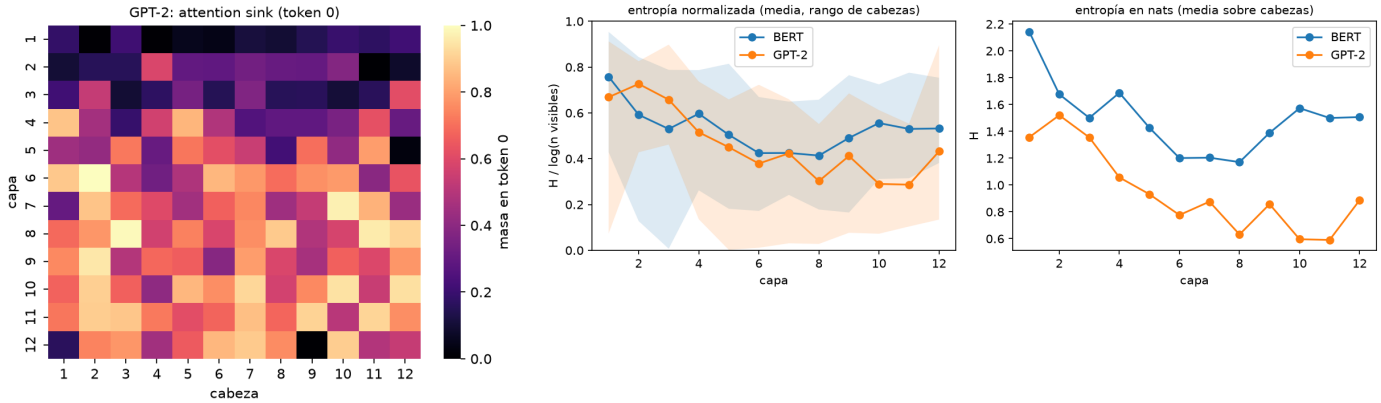
Patrones en BERT. La atención es bidireccional (matriz llena). En las capas 2–10, 48–63% de la masa media cae en *[CLS]*/*[SEP]* (la capa 6 llega a 0.63), tokens de "reposo" para cabezas sin función útil en esa posición; en las capas 1 y 11–12 solo 9–21%. Hay cabezas puramente posicionales: en la capa 4 una cabeza pone 57% de su masa en el token previo y en la capa 3 una pone 93% en el siguiente. Estos patrones coinciden con los reportados por Clark et al. (2019).

Correferencia ("it" en *…too tired* vs *…too wide*). Para cada cabeza, *r = A[it→animal]/(A[it→animal] +A[it→street])*; se consideran solo cabezas con ≥5% de masa sobre los dos candidatos (61 de 144), porque *r* es ruido si no miran a ninguno. En promedio *r* pasa de 0.712 (*tired*) a 0.531 (*wide*), es decir, el contexto sí desplaza la atención hacia *animal*, pero solo 14 de 61 cabezas (23%) resuelven bien ambos casos, **lo esperable por azar (~25%)**, y se concentran en las capas 7–12. Hay cabezas concretas con comportamiento limpio: capa 7, cabeza 11 da *it→animal*=0.28, *it→street*=0.07 con *tired* y 0.01 / 0.59 con *wide*. Pero elegir la mejor de 61 cabezas sobre un único par de oraciones es selección (comparaciones múltiples), así que no se concluye que esa cabeza "haga correferencia".



BERT: cabeza 11 de la capa 7 en las dos oraciones (izq. tired, der. wide).

GPT-2 causal. En las 144 cabezas la masa sobre posiciones futuras es exactamente 0 y cada fila suma 1 (la matriz es triangular inferior). **Attention sinks**: 80/144 cabezas dejan >50% de su atención en el token 0 (máx. 0.996) y la masa crece con la profundidad (0.12 en la capa 1, ~0.75 en capas 8–11). Es un efecto **posicional y no semántico**: al cambiar la palabra inicial (*The*, *Ban*, *Quant*, ., salto de línea) la masa se mantiene en 0.52–0.53 con las mismas ~80 cabezas, mientras que *The* en la posición 1 recibe solo 0.025. Con la máscara causal el token 0 es el único visible para todos, y como el softmax obliga a repartir masa 1, sirve de vertedero cuando una cabeza no tiene nada que leer (Xiao et al., 2023).



GPT-2: masa de atención sobre el token 0 por capa × cabeza (izq.) y entropía normalizada por capa en BERT y GPT-2 (der.).

Entropía. Se calcula $H=-\Sigma p \log p$ por fila, normalizada por *log(tokens visibles)* (en GPT-2 la fila *t* ve *t+1*), promediada sobre 6 oraciones. Ambos modelos arrancan con atención difusa (capa 1: BERT 0.76, GPT-2 0.67) y se vuelven más focalizados con la profundidad (BERT mínimo 0.41 en la capa 8; GPT-2 mínimo 0.29 en las capas 10–11, en parte por los sinks), con repunte en la última capa (0.53 y 0.43). Hay cabezas casi deterministas (entropía normalizada 0.007 y 0.002) y otras casi uniformes (0.95 y 0.91): las cabezas son heterogéneas.

5. Discusión

Escalabilidad frente a las RNN. Las RNN no se paralelizan en el tiempo (profundidad secuencial $O(T)$) y propagan la información en $O(T)$ pasos; el Transformer procesa todos los tokens a la vez y conecta cualquier par en un paso, lo que explica que escale con datos, parámetros y cómputo (leyes de escala). El costo es $O(T^2)$ en memoria y en tiempo para el contexto, y en inferencia el *KV cache* crece linealmente con T.
Especialización de cabezas. Los resultados muestran cabezas posicionales (token previo/siguiente), cabezas “de reposo” sobre *[CLS]*/*[SEP]*/token 0 y algunas con sensibilidad sintáctico-semántica (capa 7, cabeza 11); pero también redundancia: muchas cabezas se pueden podar con poca pérdida (Michel et al., 2019; Voita et al., 2019), y la mayor parte del comportamiento “interpretable” se concentra en pocas.

¿Los pesos de atención explican? Argumentos en contra (Jain y Wallace, 2019): los pesos pueden alterarse sin cambiar la predicción, y la atención no mide la importancia de un token porque el *value* y las capas siguientes también transforman la señal. Nuestros resultados lo ilustran: los *sinks* concentran 50–99%

de la atención en un token semánticamente vacío, así que “mucha atención” no equivale a “mucha influencia”. A favor (Wiegreffe y Pinter, 2019): depende de qué se entiende por explicación, y como diagnóstico de dónde se **lee** información sirve. Conclusión: es una pista útil, no una explicación causal; para atribuciones fiables hay que complementarla con intervenciones (ablación de cabezas, *attention rollout*, gradientes).

Contextos de 100,000+ tokens. T^2 es inviable: 10^5 tokens implican 10^{10} pesos por cabeza y capa. Estrategias: (i) cálculo exacto eficiente (**FlashAttention**, **ring attention** para repartir la secuencia entre dispositivos); (ii) patrones dispersos, ventana deslizante + sinks (Longformer, BigBird, **StreamingLLM**, que retiene los primeros tokens por el fenómeno anterior); (iii) extensión de posiciones (**RoPE scaling**, interpolación de posiciones, YaRN) para generalizar más allá de la longitud de entrenamiento; (iv) reducir el KV cache (MQA/GQA, cuantización, compresión); (v) arquitecturas de costo lineal (Mamba, atención lineal); (vi) no meter todo en el contexto: recuperación (RAG) y memoria externa.

Referencias

Vaswani et al. (2017). *Attention Is All You Need*. arXiv:1706.03762. · Bahdanau, Cho, Bengio (2014). *Neural Machine Translation by Jointly Learning to Align and Translate*. arXiv:1409.0473. · Luong, Pham, Manning (2015). *Effective Approaches to Attention-based NMT*. arXiv:1508.04025. · Su et al. (2021). *RoFormer: Rotary Position Embedding*. arXiv:2104.09864. · Xiong et al. (2020). *On Layer Normalization in the Transformer Architecture*. arXiv:2002.04745. · Dao et al. (2022). *FlashAttention*. arXiv:2205.14135. · Clark et al. (2019). *What Does BERT Look At?* arXiv:1906.04341. · Xiao et al. (2023). *Efficient Streaming Language Models with Attention Sinks*. arXiv:2309.17453. · Jain, Wallace (2019). *Attention is not Explanation*. arXiv:1902.10186. · Wiegreffe, Pinter (2019). *Attention is not not Explanation*. arXiv:1908.04626. · Michel, Levy, Neubig (2019). *Are Sixteen Heads Really Better than One?* arXiv:1905.10650. · Voita et al. (2019). *Analyzing Multi-Head Self-Attention*. arXiv:1905.09418. · Beltagy et al. (2020). *Longformer*. arXiv:2004.05150. · Gu, Dao (2023). *Mamba*. arXiv:2312.00752. · Peng et al. (2023). *YaRN*. arXiv:2309.00071. · Liu et al. (2023). *Ring Attention with Blockwise Transformers*. arXiv:2310.01889.